LABORATUVAR 7 · AS METAL TETRAGON · Laminat Presi

AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad	Grup	Tarih

Kavram — Prediction ≠ Safety: Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Senaryo: TETRAGON'a panel ve kaplamanın hizasını, yabancı cismi ve kabarcığı kontrol eden, buna göre baskı reçetesi seçen YZ'li görsel kontrol eklenmesi planlanıyor — proje aşaması değerlendirmesi yapıyorsunuz.

Kamera → YZ Modeli → OK / RED → Baskı parametresi → Pres

Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?
   Kaymış kaplamaya ya da yabancı cisme OK verilirse hatalı ürün çıkar. İkinci kontrol olarak baskı öncesi operatör onayı ve çıkışta görsel kontrol yapılır; hatalı OK oranı izlenir. YZ sıcaklık, süre ve basıncı yalnızca onaylı reçete aralığında seçebilir; aşırı sıcaklık sınırlayıcı ve emniyet teli YZ'den bağımsızdır.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?
   Görüntü kalitesi ve kamera bağlantısı kontrol edilir (bulanık, buhardan puslu, donmuş ya da tekrarlanan kare, zaman damgası, kimlik doğrulama). Şüpheli girdide pres kapanmaz, onaylı standart reçete seçilir, operatöre alarm gider, olay loglanır.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?
   Eşik risk değerlendirmesiyle belirlenir (örn. %95). Altında: pres kapanmaz, operatör paneli kontrol edip onaylar; ardışık düşük güvende makine durur. Fallback: YZ'siz onaylı standart reçete.

Karar tablosu — AI Fail-Safe Decision

Başarısızlık	Tanımladığınız güvenli davranış (hangi kavramla?)
Model yanlış sınıflandırdı	Operatör onayı + çıkış kontrolü, reçete onaylı aralıkta → **human override, monitoring**
Girdi manipüle edildi	Girdi doğrulanır; şüphede pres kapanmaz, standart reçete → **fail-safe, monitoring**
Confidence düştü	Eşik altı pres kapanmaz + operatör onayı; standart reçete → **confidence threshold, fallback**

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.